

Proyecto 1

Diego Alejandro Bayona Vergara - 202416663

Juan Lesmes – 202614029

Juan Sebastián Barragán Luque - 202425898

Angel Daniel Marquez Velasco - 202616507

Universidad de los Andes

Aplicación en Ciencia de Datos

Nicolas Suarez Ariza

26 de septiembre de 2026

Parte 1: Entendimiento del problema

a. *Pregunta analítica*

En una escala de 0 a 10, ¿qué tan satisfechas se sienten las personas mayores de 18 años en Bogotá con respecto a su salud, ingreso, seguridad, trabajo y tiempo libre, y cuáles de estos aspectos tienen mayor peso sobre su satisfacción general con la vida?

b. *Información necesaria*

Para responder a nuestra pregunta analítica necesitaremos de variables explicativas, así como **los índices de satisfacción de salud, los ingresos, la seguridad, el trabajo y el tiempo libre** de las muestras que estamos analizando. Además, necesitamos una variable general para contrastar las demás variables como el **índice de satisfacción a nivel general** y en último lugar, las variables con las que aplicaremos el filtro para los datos que nos interesan como la edad (estamos buscando personas mayores a 18) y el lugar (nos enfocamos en Bogotá).

Parte 2: Preparación de los datos

a. *Variables seleccionadas, su representación y su tipo de dato*

- **P6040:** Señala los años cumplidos por la persona observada. *Tipo numérica.*
- **P1895:** Índice de satisfacción general de la vida de la persona actualmente. *Tipo numérica con rango de 0-10.*
- **P1896:** Índice de satisfacción general de la persona evaluada con su ingreso actual. *Tipo numérica con rango de 0-10.*
- **P1897:** Índice de satisfacción general de la persona evaluada con su salud. *Tipo numérica con rango de 0-10.*
- **P1898:** Índice de satisfacción general de la persona evaluada con su nivel de seguridad. *Tipo numérica con rango de 0-10.*
- **P1899:** Índice de satisfacción general de la persona evaluada con su trabajo/actividad actual. *Tipo numérica con rango de 0-10.*
- **P3175:** Índice de satisfacción general de la persona evaluada con su tiempo libre. *Tipo numérica con rango de 0-10.*

b. *Filtros requeridos (edad, lugar y P753S1)*

```
def limpieza_datos(df):
    """El objetivo de esta función es el de limpiar los datos
    del dataframe, debido a que nuestro trabajo se restringe principalmente a
    personas de 18 años o mas, y que hayan vivido en bogotá los últimos 12 meses.

    Args:
        df (Dataframe) -> El archivo csv original
    Return
        df (Dataframe) -> El Dataframe ya limpio con las variables a trabajar.
    """

    # 3. Filtrar por personas de 18 años o más, la variable p6040 se refiere a los años cumplidos de cada individuo
    df_mayores18 = df[df["P6040"] >= 18]

    # 4. Filtrar por personas que vivieron en Bogotá en los últimos 12 meses
    # La variable P753S1 indica en que departamento vivió en los últimos 12 meses, el código 11 del "divipola" indica Bogotá
    df_bogota = df_mayores18[df_mayores18["P753S1"] == 11]

    return df_bogota
```

c. Calidad de los datos

Métrica	Valor
Datos Vacíos de Satisfacción General.	0
Datos Vacíos de Ingreso.	0
Datos Vacíos de Seguridad.	0
Datos Vacíos del Tiempo Libre.	0
Datos Vacíos del Trabajo.	0
Datos Vacíos de la Salud.	0
Proporción de Vacíos en la Satisfacción General	0
Proporción de Vacíos en el Ingreso.	0
Proporción de Vacíos en la Seguridad.	0
Proporción de Vacíos en el Tiempo Libre.	0
Proporción de Vacíos en el Trabajo.	0
Proporción de Vacíos en la Salud.	0


Como se aprecia en la imagen, no existe ningún valor nulo o vacío, lo que indica que, además, representan un 0% de la proporción con respecto a los registros seleccionados


d. Identificación de variables que requieran tratamiento especial

La variable *P1896* requiere de tratamiento especial. En este caso, hablamos de un índice de 0-10 para la satisfacción de una persona con sus ingresos. Sin embargo, el rango de esta variable va de 0-99. Siendo 99-98 la manera que el DANE tiene para decir que un dato no existe, o que es desconocido. Es necesario realizar la transformación de estos datos ya que, de no hacerlo, el análisis descriptivo de nuestra base de datos se puede ver completamente perjudicado. Este valor puede alterar medidas como el promedio o la varianza considerablemente.

Parte 3: Análisis descriptivo

a. Histogramas generados a partir de las variables seleccionadas





b. Relación interpretada con precaución, asociaciones observadas y relaciones causales

En la matriz de correlación de Pearson se observa una asociación positiva entre la satisfacción con el ingreso (P1896) y la satisfacción con el trabajo o actividad actual (P1899) con un coeficiente de $r = 0.5431$.

Sin embargo, debemos interpretar este resultado con precaución, ya que la existencia de una asociación estadística entre dos variables no significa que una sea la causa directa de la otra; al tratarse de una encuesta analítica de un momento específico, esta relación puede estar explicada por variables de confusión no observadas (como el nivel de ingresos absoluto, el estrato socioeconómico o el nivel educativo), estos afectan simultáneamente a ambas partes, o bien por “causalidad inversa” donde estar satisfecho con la actividad laboral influya sobre la percepción del ingreso y viceversa. Por lo tanto, para saber si existe una verdadera relación causal entre la satisfacción laboral y la del ingreso, es necesario aplicar modelos de regresión o estadística avanzada que controlen estas covariables o usar una mejor metodología.

c. Valores atípicos relevantes

Los valores extremos dentro del rango 0-10 (así como la edad hasta los 91 años) corresponden a observaciones validas que reflejan la variabilidad real de las percepciones de la ciudadanía (un dato extremo no necesariamente implica tener un outlier). El único valor atípico detectado fue el máximo de 99 en la variable de ingreso (P1896), este caso requirió un tratamiento especial de conversión de valor nulo para garantizar que dicho dato no altere los análisis del dataset.

Parte 4: Hallazgos

Los hallazgos revelan que la Satisfacción General con la Vida en la muestra alcanza un promedio elevado de 8.18 sobre 10 (mediana de 8.0). Al evaluar las cinco dimensiones analizadas, la Seguridad (8.19) y la Salud (8.09) obtienen los puntajes más altos, seguidas por el Tiempo Libre (7.81) y el Trabajo (7.64). En contraste, el Ingreso constituye la dimensión peor valorada, con una media de 6.78 (mediana de 7.0) y la mayor dispersión de respuestas. Además, la función de análisis de nulos identificó que la variable de Ingreso concentra un 15.02% de abstención o valores vacíos (38 registros), mientras que las demás variables presentan una cobertura completa.

En cuanto a la relación entre estos aspectos y la satisfacción general, la matriz de correlación del script muestra que la Salud es el factor con mayor asociación individual (0.515), seguido del Ingreso (0.476) y el Trabajo (0.465). La Seguridad (0.348) y el Tiempo Libre (0.371) exhiben las correlaciones más bajas con el bienestar global.

Sin embargo, con la información y métodos actuales no se puede concluir el peso o importancia directa de cada dimensión, ya que la correlación lineal solo mide relaciones individuales no evalúa el impacto simultáneo ni aísla el efecto de unas variables sobre otras.

Para responder a la pregunta planteada, es necesario incorporar un análisis de **regresión multivariada** en el código para determinar el peso relativo de cada dimensión, aplicar el factor de expansión para ajustar las métricas a la población total de Bogotá y realizar agrupaciones por edad, género y zonas urbanas para detectar dónde se concentran los menores niveles de satisfacción.

Parte 5: Reflexión

Lo más difícil fue traducir un concepto abstracto y complejo como el “Bienestar” en variables cuantitativas (salud, ingreso, seguridad, trabajo y tiempo libre). Esto requirió estructurar la pregunta central para evaluar percepciones en escala numerica (0-10), de tal manera que sea más facil determinar relaciones estadísticas sin asumir causalidades.

En la preparación de los datos se tomaron dos decisiones clave. Primero, se filtró la base para trabajar únicamente con mayores de 18 años residentes en Bogotá ($P6040 \geq 18$ y $P753S1 == 11$), delimitando la muestra a 253 personas para responder exactamente al público objetivo, aunque esto redujo el margen para realizar cruces sociodemográficos detallados. Y segundo, en la función **tratar_valores_especiales** se reemplazaron los códigos 98 y 99 ("No sabe / No responde") por valores nulos (NaN), conservando intacto el puntaje 9 de la escala de satisfacción; esto evitó la distorsión de los promedios y evidenció que la variable de Ingresos registra un 15.02% de abstención.