

Pautas Proyecto 1 - Fundamentos

Objetivo: Estructurar y analizar un problema de datos de manera sistemática, utilizando las etapas iniciales de CRISP-DM para formular preguntas analíticas, preparar los datos y realizar un análisis exploratorio.

Instrucciones de la entrega:

- Se debe entregar un informe en PDF a través de **Bloque Neón** junto con los archivos de soporte (códigos en Python ejecutables y otros documentos que considere necesarios)
- El documento debe tener una extensión de **máximo 5 páginas**.
- Esta actividad debe desarrollarse en grupos de **cuatro (4) estudiantes**.
- Sólo se calificará el último envío realizado.
- El código debe estar debidamente comentado.
- Cualquier sospecha de fraude será manejada de acuerdo con el reglamento de la Universidad.

Fecha máxima de entrega: domingo **27 de septiembre** de 2026 a las **11:59 p.m.**

Caso: Análisis de bienestar en la población adulta de Bogotá D.C.

La Alcaldía de Bogotá se encuentra interesada en comprender mejor las condiciones de vida y el bienestar de la población adulta de la ciudad. Aunque existen diferentes programas y estrategias orientados a mejorar el bienestar de los ciudadanos, contar con información que permita caracterizar a la población e identificar diferencias entre distintos grupos puede contribuir a orientar futuras acciones de política pública. En este contexto, la Alcaldía ha solicitado el apoyo de un equipo de consultores en Ciencia de Datos para **realizar una primera aproximación al bienestar y las condiciones de vida de la población adulta residente en Bogotá D.C.** El propósito es utilizar los datos disponibles para identificar características, diferencias y patrones que puedan aportar elementos para comprender mejor la situación de la población estudiada.

Como equipo de consultores, se les ha entregado la tabla "**Características y composición del hogar**" de la Encuesta Nacional de Calidad de Vida (ECV) 2025, realizada por el Departamento Administrativo Nacional de Estadística (DANE). La ECV es una encuesta dirigida a los hogares colombianos que recopila información sobre diferentes dimensiones del bienestar y las condiciones de vida de la población y constituye una fuente importante para el análisis de fenómenos sociales y para el diseño y seguimiento de políticas públicas.

La tabla entregada contiene información sobre las personas que conforman los hogares y su parentesco con el jefe/a del hogar, así como diferentes características demográficas de sus integrantes. Además, incluye información sobre autorreconocimiento étnico, identificación como población campesina, orientación sexual e identidad de género. Para las personas de 15 años o más, la tabla contiene además información relacionada con el bienestar subjetivo, incluyendo aspectos como la satisfacción con la vida, la salud, el ingreso, la seguridad, el trabajo y el tiempo libre.

Durante la reunión inicial, los representantes de la Alcaldía les indicaron que el análisis debe concentrar únicamente en **personas de 18 años o más que los últimos 12 meses vivieron en Bogotá** y entre los temas que les gustaría explorar se encuentran:

- **Bienestar y características de la población:** explorar cómo se relacionan diferentes características de las personas, como la edad, el sexo o el estado civil, con aspectos de su bienestar.
- **Bienestar y diversidad de la población:** explorar si existen diferencias en diferentes aspectos del bienestar entre grupos de población según su autorreconocimiento étnico.
- **Relaciones entre diferentes aspectos del bienestar:** explorar cómo se relacionan entre sí diferentes aspectos del bienestar, como la satisfacción con la vida, la salud, el ingreso, la seguridad, el trabajo y el tiempo libre.

La Alcaldía no ha definido una pregunta específica para el análisis y espera que, como consultores, sean ustedes quienes transformen estas necesidades de información en una pregunta analítica concreta que pueda ser respondida con los datos disponibles. Para ello, desarrollen las siguientes actividades:

1. Entendimiento del problema

- Formulen una pregunta cuantitativa que permita abordar uno de los temas de interés.
- Antes de consultar la base de datos, identifiquen qué información necesitan para responder su pregunta analítica. Piensen en las características, grupos o medidas que necesitarían observar o comparar para poder responderla.

2. Preparación de los datos (ETL)

- Una vez hayan definido qué información necesitan, consulten la tabla "Características y composición del hogar" y determinen cuáles variables disponibles pueden proporcionar esa información. Para cada variable seleccionada, indiquen qué representa y qué tipo de dato contiene (por ejemplo, numérico, categórico, texto, etc.). Para esto puede consultar el diccionario de datos de la ECV 2025 del DANE: [Colombia - Encuesta Nacional de Calidad de Vida - ECV - 2025](#)
- Recuerden que el análisis está dirigido a **personas de 18 años o más que los últimos 12 meses vivieron en Bogotá**. Realicen el filtro sobre la variable P753S1 antes de continuar con el análisis e indiquen cuántos registros contiene la base antes y después de aplicar el filtro.
- Para las variables seleccionadas, evalúen la **calidad de los datos**. Identifiquen cuántos valores faltantes o nulos presenta cada variable y qué proporción representan respecto al total de registros.
- **Identifiquen**, cuando corresponda, valores o categorías que puedan requerir un tratamiento especial, como "No sabe", "No responde" o valores que indiquen que una pregunta no aplica. A partir de esta revisión, indiquen si es necesario realizar algún tratamiento sobre los datos y justifiquen su decisión.

3. Análisis Descriptivo

- Para cada una de las variables seleccionadas, construyan un resumen descriptivo que permita comprender cómo se distribuyen los datos: Para las variables numéricas, calculen e interpreten medidas descriptivas relevantes, como media, mediana, mínimo y máximo; Para las variables categóricas, analicen la frecuencia de las diferentes categorías. Se recomienda explorar y visualizar la información en Histogramas o gráficos de barras.
- Identifiquen al menos una relación que deba interpretarse con precaución y expliquen por qué una asociación observada no implica necesariamente una relación causal.
- Identifiquen posibles valores atípicos en las variables relevantes para su análisis e indique si considera que estos valores corresponden a observaciones válidas, posibles errores en los datos o situaciones que requieren un tratamiento particular.

4. Hallazgos

- A partir de los resultados obtenidos, **expliquen qué pueden decirle a la Alcaldía sobre el tema analizado y cómo estos hallazgos responden a la pregunta analítica planteada.** Además indiquen qué aspectos no pueden concluir con la información disponible y qué análisis o información adicional sería necesario para profundizar en el problema.

5. Reflexión

Respondan las siguientes preguntas sobre el proceso de análisis:

- ¿Qué fue lo más difícil al momento de transformar una necesidad de información en una pregunta analítica?
- ¿Qué decisiones tuvieron que tomar durante la selección y preparación de los datos y cómo influyeron estas decisiones en el análisis?